

封面

小组项目名称：职业技能知识图谱构建与应用系统【待确认】

小组成员：吕天白（学号【待补充】）、赵金波（学号【待补充】）。如课程要求列出全部成员，请继续补充。

报告撰写时间：2026年6月12日

仓库地址：git@github.com:blackblake/Knowledge-Engineering.git（待提交当前代码覆盖远程后作为最终仓库地址）

1 小组分工

成员	主要任务	对应报告小节
吕天白	总体方案设计、数据处理、实体/关系抽取、实体对齐融合、图谱构建、存储后端、API与下游任务实现、报告主体撰写	2.1-2.7, 3.1-3.2
赵金波	参与可视化页面展示与前端交互相关工作	2.7, 3.1

成员	贡献占比	电子签
吕天白	80%	吕天白
赵金波	20%【根据总和100%暂列，待确认】	赵金波【待确认】

说明：课程要求贡献占比总和为100%。已知吕天白贡献80%，赵金波参与可视化工作，因此报告草稿暂列赵金波20%；若实际比例不同，应在提交前修改。

2 知识图谱构建

2.1 数据源、获取方法和原始数据统计信息

本项目面向招聘岗位场景构建职业-技能知识图谱。主要数据源为本地处理后的岗位描述样本 jd_sample.jsonl，以及由 O*NET/本地规则整理得到的 formal_gazetteer.jsonl。岗位数据包含岗位标题、语言和岗位描述文本；词表覆盖职业、技能、工具、知识等实体类型。

数据文件	用途	统计
data/processed/crf/jd_sample.jsonl	岗位标题与岗位描述原始输入	10000条岗位记录
data/processed/full_weak_ner.jsonl	弱监督实体抽取/构图输入	35962条句级样本
data/processed/full_gazetteer.jsonl	实体规范词表与别名	9168条规范词条

知识图谱构建流程



完整输入：10000条岗位；弱标注样本：35962条；gazetteer：9168条；抽取关系：11606条。

核心关系：REQUIRES_SKILL、USES_TOOL、REQUIRES_KNOWLEDGE；增强关系：SIMILAR_TO、PREREQUI!!

图2 构建流程与统计信息。

图2 知识图谱构建流程

2.2 实体抽取的输入、方法和结果

实体抽取输入为岗位标题与岗位描述句子。系统先清洗岗位标题作为 OCC 职业实体，再用 gazetteer 建立 n-gram 索引，对岗位描述进行最长匹配，识别 SKL 技能、TOL 工具、KNW 知识等实体。该方法可解释、可复现，并能保证 Java、Python、React、Spring 等关键技术词进入图谱。

```
def _find_term_mentions(text, term_index):
    tokens, token_spans = tokenize_with_spans(text)
    for start in range(len(tokens)):
        for end in range(min(len(tokens), start + MAX_TERM_TOKENS), start, -1):
            entry = term_index.get(tuple(t.casefold() for t in tokens[start:end]))
            if entry:
                # mention: text/start/end/type/canonical_id
                ...
```

实体抽取结果：生成35962条弱监督NER样本，覆盖9168条gazetteer词条中的4176个可索引术语。职业标题经过编号、奖金信息、括号信息等清洗，减少了脏职业节点。

2.3 关系抽取的输入、方法和结果

关系抽取输入为已标注实体的句子。每条样本至少包含一个 OCC 职业实体，系统将句中其他实体与最近的职业实体建立关系。不同实体类型映射到不同关系：SKL -> REQUIRES_SKILL, TOL -> USES_TOOL, KNW -> REQUIRES_KNOWLEDGE。

```

_RELATION_MAP = {'SKL': 'REQUIRES_SKILL', 'KNW': 'REQUIRES_KNOWLEDGE', 'TOL': 'USES_TOOL'}
def extract_relations(example):
    spans = extract_entity_spans(example)
    occupations = [s for s in spans if s.entity_type == 'OCC']
    for span in spans:
        relation = _RELATION_MAP.get(span.entity_type)
        closest = min(occupations, key=lambda occ: abs(occ.start_token - span.start_token))

```

关系类型	数量
REQUIRES_SKILL	4959
USES_TOOL	4942
REQUIRES_KNOWLEDGE	1705
SIMILAR_TO	1670858
PREREQUISITE_OF	12

2.4 实体消歧的输入、方法和结果

实体消歧输入为关系抽取阶段产生的实体文本与gazetteer规范词条。系统先使用规范化精确匹配，再使用fuzzy matching进行相似度对齐，并在融合阶段合并同一canonical_id下的别名和重复关系。对齐结果：head coverage=0.9307，tail coverage=0.9932；融合后实体2630个，融合关系11606条，合并别名3206个。

2.5 事件抽取

本项目未单独实现事件抽取模块。原因是课程项目核心目标是职业-技能知识图谱及其下游应用，岗位文本中的事件结构较弱，主要信息以实体和实体关系形式表达。

2.6 其他：知识推理与图谱增强

系统在基础抽取关系之外构建SIMILAR_TO职业相似关系和PREREQUISITE_OF技能先修关系。SIMILAR_TO根据职业技能集合重叠度生成，用于成长路径规划；PREREQUISITE_OF根据技能全局出现频次构造启发式先修链，用于展示知识推理能力。

2.7 知识图谱的规模、存储和可视化结果

指标	数值
节点数	2630
边数	1682476
抽取关系数	11606
存储后端	CSV文件 + Neo4jGraphStore适配层
网页可视化	FastAPI + vis-network; 默认展示高证据子图，避免百万边前端卡顿




图1 系统架构：岗位数据进入构建流水线，生成图谱并通过网页应用提供下游任务。

图1 系统架构与存储/可视化方式

3 基于知识图谱的应用

3.1 系统基本功能

系统提供一个本地网页应用，包含图谱可视化和四类下游任务：岗位推荐、技能差距分析、职业成长路径规划和岗位画像查询。用户输入技能列表或目标职业后，前端调用FastAPI接口，后端基于GraphStore从完整图谱中检索与计算结果。

下游应用运行结果

输入技能: Java, Spring, SQL

岗位推荐 Top-5

1. Big Data Developer/Java | 命中:3 分数:0.395519
2. AI Developer | 命中:3 分数:0.097461
3. Back-End-Developer | 命中:3 分数:0.082324
4. Automation QA engineer | 命中:3 分数:0.100417
5. Automation QA | 命中:3 分数:0.114762

技能差距示例: Python Developer + 已掌握 Python

输出: missing_skills = [], 说明当前输入覆盖该岗位已抽取核心技能。

图3 由真实 API 输出渲染的应用结果截图。

图3 下游任务运行结果示例

功能	输入	输出
岗位推荐	技能列表, 例如Java, Spring, SQL	推荐相关岗位及命中数、分数
技能差距	目标岗位 + 已掌握技能	仍缺少技能/工具/知识
成长路径	源岗位 + 目标岗位	基于SIMILAR_TO的路径
岗位画像	岗位名称	该岗位关联技能、工具、知识和证据数

3.2 如何使用知识图谱的实现细节

网页应用不是静态写死结果, 而是通过统一GraphStore接口使用知识图谱。CSVGraphStore和Neo4jGraphStore暴露相同方法: summary、graph_raw、occupation_profile、recommend、skill_gap和growth_path。因此系统可以在CSV后端与Neo4j后端之间切换。

```
def recommend(self, skills, top_k):
    skill_set = {_normalize(skill) for skill in skills}
    for edge in self.edges:
        if edge['relation'] in {'REQUIRES_SKILL', 'USES_TOOL', 'REQUIRES_KNOWLEDGE'}:
            # OCC -> SKL/TOL/KNW 证据强度
            ...
    return ranked[:top_k]
```

以岗位推荐为例, 系统只统计OCC职业节点指向SKL/TOL/KNW节点的关系边。输入技能被规范化后与图谱节点名称匹配, 命中边按evidence_count的log权重累积, 并综合命中技能数、标题命中和证据强度排序。

以技能差距为例, 系统查询目标职业的REQUIRES_SKILL边, 与用户已掌握技能集合做差集, 输出缺失技能、是否核心要求、证据数和熟练度信息。

提交说明

本报告已按课程要求组织为：封面、小组分工、知识图谱构建、基于知识图谱的应用。最终提交形式为PDF。当前草稿中仍需人工确认的字段包括：项目正式名称、成员学号、赵金波贡献占比/电子签，以及是否需要列出除吕天白和赵金波以外的全部成员。

GitHub仓库地址要求为git@github.com:blackblake/Knowledge-Engineering.git。由于覆盖远程仓库属于有风险操作，需要在提交前确认当前工作区内容、远程权限和是否允许force push。